POLARIS IRT Core：大语言模型自适应能力评测平台

> **定位**：基于 IRT+CAT 的自动化 LLM 能力评测平台
> **核心承诺**：提交模型 → 自动评测 → 实时更新排行榜，全程无人工干预
> **口号**：*Submit Once, Ranked by Science*

1. 产品核心逻辑

1.1 一句话描述

用户提交模型 API，平台自动运行 IRT 自适应测试，输出带置信区间的能力参数 θ，实时更新全球排行榜。

1.2 与现有平台的本质差异

对比维度	MMLU / OpenCompass	Chatbot Arena	POLARIS IRT Core
测量结果	原始正确率（依赖题目分布）	ELO（依赖对手集）	**θ（绝对能力量尺）**
置信区间	✗	✗	**✓ 每个结果附带 SE**
测试效率	全量（200+ 题）	人工（慢）	**自适应（≈20 题）**
更新速度	人工提交 + 手动跑	等待用户投票	**提交后 30 分钟出结果**
题库安全	题目公开，已泄露	无题库概念	**CAT 随机选题 + 曝光控制**
跨版本可比	✗ 不同题集不可比	✗ 对手集变化后漂移	**✓ 固定量尺，v1→v2 可比**

1.3 核心用户流程

```
┌──────────────────────────────────────────────────────────────┐
│                        用户侧（5分钟完成）                        │
│                                                                │
│  1. 注册账号                                                    │
│  2. 填写模型信息（名称/版本/描述）                                  │
│  3. 粘贴 API Endpoint + API Key（或上传本地模型配置）              │
│  4. 选择评测领域（全选 or 指定领域）                                │
│  5. 提交 → 等待                                                 │
└──────────────────────────────────────────────────────────────┘
                              │
                              ▼
┌──────────────────────────────────────────────────────────────┐
│                        平台侧（全自动）                          │
│                                                                │
│  验证 API 可用性 → 队列调度 → CAT 自适应测试                       │
│  → θ + SE 估计 → 生成报告 → 更新排行榜                            │
│  → 通知用户（邮件/站内信）                                         │
└──────────────────────────────────────────────────────────────┘
```

2. 网站功能设计

2.1 页面结构总览

```
POLARIS
├── 首页（Landing Page）
├── 排行榜（Leaderboard）          ← 核心页面
│   ├── 综合排行榜
│   ├── 按领域排行榜
│   └── 能力雷达图对比
├── 模型详情页（Model Profile）
├── 提交评测（Submit）             ← 核心入口
│   ├── API 提交
│   └── 本地模型提交（vLLM/Ollama）
├── 评测进度（Dashboard）
├── 题库市场（Question Hub）       ← 社区贡献
├── API 文档（Developers）
└── 关于（About / Methodology）
```

2.2 核心页面详细设计

页面 1：排行榜（Leaderboard）

这是平台最重要的页面，设计要兼顾信息密度和直觉可读性。

```
┌──────────────────────────────────────────────────────────────────────────┐
│  POLARIS Leaderboard                                 更新时间: 实时        │
│                                                                          │
│  筛选: [全部领域 ▾] [全部规模 ▾] [开源/闭源 ▾] [时间范围 ▾]               │
│                                                                          │
│  ┌────┬──────────────┬────────┬──────────┬────┬────────┐                │
│  │ 排名 │ 模型         │ 综合 θ │ 95% 置信区 │ 题量 │ 更新   │          │
│  ├────┼──────────────┼────────┼──────────┼────┼────────┤                │
│  │  1 │ Qwen3-72B    │  2.41  │[2.18,2.64]│ 28 │ 1h ago │              │
│  │  2 │ DeepSeek-V3  │  2.38  │[2.15,2.61]│ 31 │ 2h ago │              │
│  │  ≈ │ ── 与第1名统计上无显著差异 ──                                    │
│  │  3 │ GPT-4o       │  2.21  │[2.01,2.41]│ 25 │ 6h ago │              │
│  │  4 │ Llama-3.3-70B│  1.94  │[1.74,2.14]│ 22 │ 1d ago │              │
│  │  5 │ Mistral-Large│  1.87  │[1.65,2.09]│ 27 │ 2d ago │              │
│  └────┴──────────────┴────────┴──────────┴────┴────────┘                │
│                                                                          │
│  ⚠️  排名1-2的模型置信区间重叠，统计上无显著差异                          │
│                                                                          │
│  [导出 CSV]  [分享排行榜快照]  [查看历史变化]                             │
└──────────────────────────────────────────────────────────────────────────┘
```

领域切换标签（点击切换不同领域排名）：

```
[综合] [数学] [代码] [逻辑推理] [中文理解] [知识问答] [多语言]
```

可视化组件：置信区间森林图

```
模型            θ 估计值（95% CI）
──────────────────────────────────────────
Qwen3-72B       ──────●──────
DeepSeek-V3     ──────●──────
GPT-4o            ────●────
Llama-3.3-70B       ────●────
Mistral-L           ────●────
                1.5  2.0  2.5  3.0   θ
```

页面 2：模型详情页（Model Profile）

```
┌──────────────────────────────────────────────────────────────────────────┐
│  Qwen3-72B                                    提交方：Alibaba Cloud      │
│  综合 θ = 2.41 ± 0.23   |   评测题量：28题   |   更新：1h ago            │
├──────────────────────────────────────────────────────────────────────────┤
│                                                                          │
│  领域能力雷达图                          各领域 θ 明细                   │
│                                                                          │
│          数学                            领域        θ      SE    题量   │
│          2.8                              数学       2.80   0.21   6     │
│    多语  ────  代码                      代码       2.61   0.24   5     │
│    2.1       2.6                         逻辑推理   2.33   0.19   7     │
│         \  /                             中文理解   2.19   0.22   5     │
│    知识  ────  逻辑                      知识问答   1.98   0.25   5     │
│    2.0       2.3                         多语言     2.11   0.23   6     │
│                                                                          │
├──────────────────────────────────────────────────────────────────────────┤
│  版本历史（能力演进曲线）                                                │
│                                                                          │
│  θ ▲                                                                     │
│  2.5│                                          ●  Qwen3-72B             │
│  2.0│                              ●                                    │
│  1.5│                ●                                                  │
│  1.0│    ●                                                              │
│     └──────────────────────────────────────────────→ 时间              │
│        Qwen-7B   Qwen2-72B  Qwen2.5-72B  Qwen3-72B                       │
├──────────────────────────────────────────────────────────────────────────┤
│  行为维度剖面（Behavioral Profile）                                      │
│                                                                          │
│  鲁棒性 R_std = +0.82  ▓▓▓
```

页面 3：提交评测（Submit）

设计原则：5分钟内完成提交，零技术门槛

```
┌──────────────────────────────────────────────────────────────────┐
│  提交模型评测                                                      │
├──────────────────────────────────────────────────────────────────┤
│                                                                  │
│  Step 1 / 3: 模型基础信息                                          │
│                                                                  │
│  模型名称     [Qwen3-72B-Instruct              ]                  │
│  版本号       [v1.0                            ]                  │
│  模型描述     [可选，将展示在排行榜模型详情页     ]                  │
│  机构/个人    [Alibaba Cloud                   ]                  │
│  模型规模     [○ <7B  ○ 7B-13B  ○ 30B-70B  ● 70B+]               │
│  开源状态     [● 开源  ○ 闭源]                                     │
│  HuggingFace链接 [可选                         ]                  │
│                                                                  │
│                                          [下一步 →]              │
└──────────────────────────────────────────────────────────────────┘
```

```
┌──────────────────────────────────────────────────────────────────┐
│  Step 2 / 3: 模型接入方式                                          │
├──────────────────────┬───────────────────────────────────────────┤
│  ● API 接入（推荐）    │  ○ 本地部署接入                            │
├──────────────────────┴───────────────────────────────────────────┤
│                                                                  │
│  API Endpoint   [https://your-api.com/v1/chat/completions]       │
│  API Key        [sk-••••••••••••••••••••  ] [验证连接]            │
│  请求格式        [● OpenAI 兼容  ○ 自定义]                          │
│                                                                  │
│  ── 高级设置（可选） ──────────────────────────────────────        │
│  Temperature    [0.0]   Max Tokens  [2048]                       │
│  System Prompt  [留空使用默认                                ]      │
│                                                                  │
│  ✓ API 连通性验证通过                                               │
│                                                                  │
│                         [← 上一步]  [下一步 →]                     │
└──────────────────────────────────────────────────────────────────┘
```

```
┌──────────────────────────────────────────────────────────────────┐
│  Step 3 / 3: 评测配置                                              │
├──────────────────────────────────────────────────────────────────┤
│                                                                  │
│  评测领域（可多选）                                                  │
│  ☑ 数学推理     ☑ 代码能力     ☑ 逻辑推理                          │
│  ☑ 中文理解     ☑ 知识问答     ☑ 多语言                            │
```

```
│                                                                    │
│  评测精度                                                          │
│  ● 标准（SE < 0.25，约 20-30 题/领域，约 30 分钟）                 │
│  ○ 快速（SE < 0.35，约 12-18 题/领域，约 15 分钟）                 │
│  ○ 精确（SE < 0.18，约 35-50 题/领域，约 60 分钟）                 │
│                                                                    │
│  结果可见性                                                        │
│  ● 公开（结果展示在排行榜）                                        │
│  ○ 私有（仅自己可见，不上榜）       [企业版功能]                   │
│                                                                    │
│  预计费用：免费（公开提交永久免费）                                │
│  预计完成：约 30 分钟                                              │
│  完成后通知：[your@email.com             ]                         │
│                                                                    │
│            [← 上一步]  [确认提交，开始评测 ✓]                      │
└────────────────────────────────────────────────────────────────────┘
```

页面 4：评测进度仪表板（Dashboard）

```
┌──────────────────────────────────────────────────────────────────────┐
│  我的评测任务                                                          │
├──────────────────────────────────────────────────────────────────────┤
│                                                                      │
│  Qwen3-72B-Instruct                              提交于 14:32         │
│  ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 68%  进行中          │
│                                                                      │
│  领域进度:                                                             │
│  数学推理    ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓ 完成   θ=2.80, SE=0.21          │
│  代码能力    ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓ 完成   θ=2.61, SE=0.24          │
│  逻辑推理    ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓ 进行中   已用7题，当前θ≈2.4     │
│  中文理解    ▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒ 等待中                    │
│  知识问答    ▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒ 等待中                    │
│  多语言      ▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒▒ 等待中                    │
│                                                                      │
│  预计完成：约 18 分钟                          [取消评测]              │
├──────────────────────────────────────────────────────────────────────┤
│  历史评测记录                                                          │
│                                                                      │
│  Qwen2.5-72B   完成   2026-03-01   θ=2.19   [查看报告]                │
│  Qwen2-72B     完成   2025-11-15   θ=1.89   [查看报告]                │
└──────────────────────────────────────────────────────────────────────┘
```

页面 5：能力对比工具（Compare）

```
┌──────────────────────────────────────────────────────────────────────┐
│  模型能力对比                                                          │
│                                                                        │
│  选择模型：[Qwen3-72B ×] [DeepSeek-V3 ×] [GPT-4o ×] [+ 添加]   │
├──────────────────────────────────────────────────────────────────────┤
│                                                                        │
│  综合能力对比（森林图）                                                  │
│                                                                        │
│  Qwen3-72B     ────────●────────          θ = 2.41 ± 0.23          │
│  DeepSeek-V3   ────────●────────          θ = 2.38 ± 0.23          │
│  GPT-4o            ────────●────────      θ = 2.21 ± 0.20          │
│                 2.0   2.3   2.6   θ                                  │
│                                                                        │
│  ⚠️ Qwen3-72B 与 DeepSeek-V3 置信区间重叠，统计上无显著差异      │
│                                                                        │
├──────────────────────────────────────────────────────────────────────┤
│  分领域对比热力图                                                      │
│                                                                        │
│              数学    代码    逻辑    中文    知识    多语              │
│  Qwen3-72B   2.80  2.61  2.33  2.19  1.98  2.11                      │
│  DeepSeek-V3 2.71  2.88  2.29  2.15  2.04  1.97                      │
│  GPT-4o      2.55  2.70  2.18  1.92  2.21  2.33                      │
│  （深绿=高，浅色=低，数字为 θ 值）                                      │
│                                                                        │
│  [导出对比报告]  [分享此对比]                                          │
└──────────────────────────────────────────────────────────────────────┘
```

页面 6：题库贡献（Question Hub）

```
┌──────────────────────────────────────────────────────────────────────┐
│  题库贡献中心                                                          │
│                                                                        │
│  帮助扩充 POLARIS 题库，高质量题目经审核后入库，贡献者永久署名。      │
├──────────────────────────────────────────────────────────────────────┤
│  [提交单道题目]  [批量上传（CSV)]  [查看我的贡献]                      │
├──────────────────────────────────────────────────────────────────────┤
│                                                                        │
│  题目质量要求:                                                         │
│  ✓ 有明确的标准答案（或评分标准）                                      │
│  ✓ 答案解析完整（用于 FDC 特征提取）                                   │
│  ✓ 难度覆盖不同层次（简单/中等/困难）                                  │
│  ✓ 不与已有题库重复（系统自动检测）                                    │
│                                                                        │
│  审核流程:                                                             │
│  提交 → AI 初审（3分钟）→ FDC 预标定 → 人工抽样验证 → 入库            │
│                                                                        │
│  贡献者权益:                                                           │
│  · 题目入库后展示"由 XX 贡献"                                          │
│  · 贡献题量 > 50 题：获得"题库贡献者"认证徽章                          │
│  · 贡献题量 > 200 题：获得无限免费私有评测额度                         │
│                                                                        │
│  当前题库状态:                                                         │
│  总题量 8,432 题  |  本月新增 312 题  |  贡献机构/个人 47 个           │
└──────────────────────────────────────────────────────────────────────┘
```

3. 技术实现方案

3.1 系统架构

```
                    ┌──────────────┐
                    │  用户浏览器  │
                    └──────────────┘
                          │ HTTPS
                          ▼
                    ┌──────────────┐
                    │ Next.js 14   │  前端（SSR+实时更新）
                    │ + shadcn/ui  │
                    └──────────────┘
                          │ REST / WebSocket
                          ▼
                  ┌──────────────────┐
                  │ FastAPI Gateway  │  API 网关 + 鉴权
                  └──────────────────┘
                          │
                          │
        ┌─────────────────┼─────────────────┐
        ▼                 ▼                 ▼
┌──────────────┐   ┌──────────────┐   ┌──────────────┐
│ 评测调度器   │   │ IRT Engine   │   │ 题库服务     │
│ Task Queue   │   │              │   │              │
│ (Celery)     │   │ FDC 标定     │   │ 题参存储     │
│ 优先级队列   │   │ MFI+ 选题    │   │ 曝光追踪     │
│ 并发控制     │   │ EAP 估计     │   │ 题目管理     │
└──────────────┘   └──────────────┘   └──────────────┘
        │                 │                 │
        └─────────────────┼─────────────────┘
                          │
                          ▼
                  ┌──────────────────┐
                  │ 数据层           │
                  │ PostgreSQL       │  题库/结果/用户
                  │ Redis            │  队列/缓存/实时
                  │ S3               │  模型响应存储
                  │ pgvector         │  题目 embedding
                  └──────────────────┘
```

3.2 评测全自动流水线

```
用户提交
    │
    ▼
┌──────────────────────────────────────────────┐
│  Step 1: 预检（~30秒）                          │
│  · 验证 API 可达性（发送测试 prompt）              │
│  · 检测响应格式（OpenAI 兼容 / 自定义 parser）     │
│  · 估算速率限制（调整并发数）                      │
└──────────────────────────────────────────────┘
                      │
                      ▼
┌──────────────────────────────────────────────┐
│  Step 2: 队列调度（秒级）                        │
│  · 按领域拆分为独立子任务（6个领域 = 6个子任务）   │
│  · 按模型历史 θ 估计初始化先验（加速收敛）         │
│  · 并发执行（默认 3 个领域同时测试）              │
└──────────────────────────────────────────────┘
                      │
                      ▼
┌──────────────────────────────────────────────┐
│  Step 3: CAT 自适应测试（每领域 15-30 分钟）      │
│                                               │
│  while SE > threshold AND n_items < budget:   │
│      item = MFI+.select(θ, pool, exposure)    │
│      prompt = item.to_prompt()                │
│      response = model_api.call(prompt)        │
│      answer = parser.extract(response)        │
│      score = grader.grade(answer, item.answer) │
│      θ, SE = EAP.update(θ, SE, item, score)   │
│      exposure[item.id] += 1                   │
│                                               │
│  → 结果: θ, SE, n_items, response_log         │
└──────────────────────────────────────────────┘
                      │
                      ▼
┌──────────────────────────────────────────────┐
│  Step 4: 结果处理与发布（~1分钟）                 │
│  · 聚合各领域 θ → 综合 θ（加权平均）              │
│  · 计算行为维度 R_std, P_std（探针题结果）        │
│  · 生成模型报告（HTML + PDF）                    │
│  · 写入排行榜数据库                              │
```

```
│   · 触发前端实时更新（WebSocket push）                │
│   · 发送完成通知邮件                                  │
└──────────────────────────────────────────────────────┘
```

3.3 关键技术模块

自动答案解析（Answer Parser）

不同题型用不同解析策略，支持全自动评分：

```python
class AnswerParser:
    def grade(self, response: str, item: Item) -> float:
        match item.answer_type:
            case "multiple_choice":
                # 提取 A/B/C/D，精确匹配
                return self._extract_choice(response) == item.answer
            case "numeric":
                # 提取数字，允许等价形式（0.5 == 1/2）
                return self._extract_number(response) ≈ item.answer
            case "short_answer":
                # GPT-4o-mini 作为裁判（judge），批量低成本
                return self._llm_judge(response, item.answer, item.rubric)
            case "code":
                # 执行代码，验证输出
                return self._execute_and_verify(response, item.test_cases)
```

实时排行榜更新

```python
# 评测完成后触发
async def publish_result(model_id: str, result: EvalResult):
    # 1. 写入数据库
    await db.upsert_model_score(model_id, result)

    # 2. 重新计算排名（增量更新，不全量重排）
    affected_rank_range = await leaderboard.update_rank(model_id, result.theta)

    # 3. WebSocket 推送给所有在线用户
    await ws_manager.broadcast({
        "event": "leaderboard_updated",
        "model": model_id,
        "theta": result.theta,
        "se": result.se,
        "rank": affected_rank_range
    })

    # 4. 通知提交者
    await email.send_completion(model_id, result)
```

曝光控制（题库安全）

```python
class ExposureTracker:
    """跨所有评测任务追踪题目使用次数"""

    def get_available_items(self, pool: ItemPool,
                            selected: Set[int]) -> List[Item]:
        available = []
        for item in pool:
            if item.id in selected:
                continue
            # 曝光上限：单题最多被 20% 的模型使用
            if self.counts[item.id] >= self.e_max:
                continue
            available.append(item)

        # 若全部达到上限（极端情况），临时忽略限制并告警
        if not available:
            logger.warning("All items at exposure limit, ignoring constraint")
            available = [i for i in pool if i.id not in selected]

        return available
```

3.4 本地模型接入（零门槛）

支持用户在本地部署模型后，通过 POLARIS CLI 接入：

```
# 安装 POLARIS CLI
pip install polaris-eval

# 一键启动本地评测代理
polaris agent start \
  --model ollama/qwen3:72b \     # 支持 Ollama / vLLM / HuggingFace
  --api-key YOUR_POLARIS_KEY \
  --domains math,code,reasoning

# 代理自动:
# 1. 注册临时 endpoint 到 POLARIS 平台
# 2. 接收平台发来的题目 prompt
# 3. 本地推理，返回结果
# 4. 结果上传，更新排行榜
```

3.5 技术选型汇总

组件	技术	说明
前端	Next.js 14 + TypeScript	SSR 支持 SEO + 实时更新
UI 组件	shadcn/ui + Tailwind	快速构建专业界面
数据可视化	D3.js + Recharts	森林图、雷达图、历史曲线
后端 API	FastAPI + Python	异步高性能
任务队列	Celery + Redis	评测任务调度
数据库	PostgreSQL + pgvector	题库 + embedding 存储
缓存	Redis	排行榜热数据
对象存储	S3 兼容（MinIO 自建）	响应日志存储
实时通信	WebSocket（FastAPI）	排行榜实时推送
IRT 计算	Python（NumPy/SciPy）	EAP 估计、Fisher 信息
题目嵌入	Qwen3-embedding-8B	FDC 特征提取
LLM 裁判	GPT-4o-mini	开放题型自动评分

组件	技术	说明
部署	Docker + Kubernetes	评测并发弹性扩缩容
监控	Prometheus + Grafana	队列深度、API 延迟
CI/CD	GitHub Actions	自动化测试和部署

4. 影响力策略

4.1 冷启动三步法

第一步（上线前）：数据先行

- 自行评测 50+ 主流开源模型，上线即有内容
- 涵盖：Qwen 系列、LLaMA 系列、DeepSeek 系列、Mistral 系列
- 让排行榜第一天就是有参考价值的，而非空榜

第二步（上线初期）：论文锁定可信度

- IRT-LLM-Eval 论文作为方法论背书（已在投稿中）
- 每次排行榜结果配方法论摘要，可链接到论文
- 核心信息：**"POLARIS 是唯一有置信区间的 LLM 排行榜"**

第三步（规模化）：让缺席成为信息

- 主动联系未入榜的知名模型厂商
- 话术："*您的模型目前未在 POLARIS 收录，建议提交以完整市场信息*"
- 让"不在 POLARIS"变成一种信息缺失，形成提交压力

4.2 差异化传播角度

传播点	内容	目标受众
置信区间排名	"第1名和第2名统计上没有显著差异"	研究者、媒体
版本演进曲线	"Qwen 系列能力从 θ=1.2 增长到 θ=2.4"	行业分析

传播点	内容	目标受众
鲁棒性揭秘	"某模型正确率高但被追问后立刻反转"	工程师
48小时快评	新模型发布后48小时内出评测结果	媒体、社区
免费开放提交	公开提交永久免费	开源社区

4.3 内容营销节奏

```
每周:    更新排行榜快照，发布在 X/Twitter、知乎
每月:    发布"月度能力榜变化"分析报告（1页 PDF）
每季度:  发布 POLARIS State of LLMs 深度报告
实时:    新模型发布后 48h 内发布快评推文
```

5. 性能可靠性保障

5.1 结果可信的五道防线

```
防线1：统计门槛
  → SE > 0.25 时继续选题，不提前结束
  → 发布结果时标注"评测充分度"（题量 + SE）

防线2：题库安全
  → MFI+ 曝光控制（单题最大曝光率 < 20%）
  → 泄露检测：正确率显著高于 IRT 预测值时触发警告
  → 每季度滚动替换 15–20% 题目

防线3：量尺稳定
  → 每领域 10 道锚题，跨批次量尺校正
  → 历史 θ 值不会因新模型加入而改变

防线4：答案评分
  → 选择题/数值题：确定性自动评分
  → 开放题：LLM-as-Judge + 一致性校验（两次裁判不一致则人工复核）

防线5：异常检测
  → 模型响应速度异常（太快/超时）→ 记录并标注
  → 答案格式异常（拒绝回答/乱码）→ 记 0 分并记录
  → 整体表现偏差过大（>3σ）→ 人工复查后再发布
```

5.2 系统可用性

```
评测任务隔离：每个模型评测在独立容器中运行，互不干扰
失败重试：子任务失败自动重试 3 次（指数退避）
结果保留：所有模型响应日志保留 90 天，可审计
排行榜缓存：读操作走 Redis 缓存，写操作队列化，确保高并发下稳定
```

6. 商业化路径（保证公开排名永久免费）

服务	用户	定价
公开排名（标准评测）	所有人	**永久免费**
私有评测（结果不上榜）	企业内部测试	付费
竞品对比报告	企业	付费
评测 API（批量调用）	研究团队	按量付费
优先队列（快速出结果）	模型发布冲刺期	付费
自定义题库评测	垂直领域企业	定制付费

7. 路线图

```
Phase 0（当前）：技术验证
  ✓ IRT-LLM-Eval 方法论完成
  ✓ FDC + MFI+ 实验验证
  □ 内部跑通 30 个模型的评测流水线

Phase 1（0-3个月）：MVP 上线
  □ 核心页面上线：排行榜 + 提交 + 模型详情
  □ 覆盖 50+ 开源模型，5 个领域
  □ 公开 API 文档
  □ 发布平台介绍博客 + 论文预印本

Phase 2（3-6个月）：功能完善
  □ 本地模型接入（CLI）
  □ 题库贡献市场
  □ 版本演进曲线
  □ 对比工具页面
  □ 第一份季度报告

Phase 3（6-12个月）：生态扩展
  □ HuggingFace 模型卡片集成
  □ 多模态评测（代码执行、图文）
  □ 企业私有评测付费功能
  □ 开放评测 API
```

8. 一句话核心定位

> **POLARIS IRT Core：提交 API，30 分钟，获得带置信区间的能力参数——LLM 评测的科学基准。**

文档版本：v1.0-IRT-Core | 日期：2026-04